



Instituto Tecnológico de Estudios Superiores de Monterrey
Campus Estado de México

TC3009C.601

M2 - Análisis

“Análisis de desempeño de K-Means”

Mario Oropeza Pérez A01660605

Gpo 601

16 de Septiembre del 2026

Análisis de desempeño de K-Means sobre el conjunto Iris

evaluación de bias, varianza y ajuste del modelo

Resumen

En este trabajo se evaluó el desempeño de la implementación de K-Means utilizada en la entrega anterior sobre el conjunto Iris. El dataset se separó en entrenamiento, validación y prueba para revisar el comportamiento del modelo fuera de los datos utilizados durante el ajuste. El modelo base obtuvo 88.89% de accuracy en entrenamiento, 93.33% en validación y 86.67% en prueba. A partir de estas diferencias se diagnosticó un bias medio, varianza baja y un underfit leve. Después se realizó un ajuste usando únicamente el conjunto de validación. La configuración final utilizó las dos variables del pétalo y alcanzó 93.33% de accuracy en prueba, con bias bajo, varianza baja y un nivel de ajuste considerado fit.

1. Introducción

K-Means es un algoritmo de clustering que agrupa observaciones de acuerdo con su distancia a un conjunto de centroides. En la entrega anterior se utilizó este algoritmo sobre Iris y se evaluó la relación entre los clusters encontrados y las tres especies del dataset. Para esta segunda parte se conserva la misma implementación con scikit-learn, pero el análisis se amplía para revisar cómo cambia el desempeño entre entrenamiento, validación y prueba.

Las etiquetas de especie no participan en el ajuste de K-Means. Se utilizan después del entrenamiento para relacionar cada cluster con la especie mayoritaria y así poder calcular métricas de clasificación que faciliten la comparación entre conjuntos.

2. Objetivo

El objetivo es evaluar el comportamiento del modelo con conjuntos separados de entrenamiento, validación y prueba, diagnosticar el grado de bias y varianza, determinar si el modelo presenta underfit, fit u overfit y aplicar un ajuste de parámetros que mejore su desempeño sin utilizar el conjunto de prueba para seleccionar la configuración.

3. Metodología

3.1 Dataset y separación de datos

Se utilizó el conjunto Iris disponible en `sklearn.datasets`. El dataset contiene 150 observaciones, 50 por especie, y cuatro variables numéricas: longitud y ancho del sépalo, y longitud y ancho del pétalo. La separación se realizó de forma estratificada con `random_state = 42` para conservar la proporción de las tres especies.

Conjunto	Observaciones	Proporción
Entrenamiento	90	60%
Validación	30	20%
Prueba	30	20%

El conjunto de validación se utilizó para comparar configuraciones y elegir el ajuste. El conjunto de prueba se mantuvo separado hasta terminar esa selección, de forma que funcionara como una evaluación final.

3.2 Modelo base

Como punto de partida se mantuvo la configuración de la implementación anterior: `k = 3`, inicialización `k-means++`, 20 inicializaciones, máximo de 300 iteraciones, tolerancia de 0.0001 y `random_state = 42`. El modelo utiliza las cuatro variables originales del dataset.

4. Resultados del modelo base

4.1 Desempeño en Train, Validation y Test

La tabla siguiente compara el desempeño del mismo modelo en los tres conjuntos. Accuracy y F1 permiten revisar la coincidencia entre los clusters y las especies, mientras que silhouette describe la separación interna de los grupos.

Conjunto	Accuracy	F1 macro	Silhouette
Train	88.89%	88.57%	0.5755
Validation	93.33%	93.27%	0.5625
Test	86.67%	86.53%	0.4723

El accuracy de entrenamiento fue de 88.89%. Validación quedó ligeramente por arriba con 93.33%, mientras que prueba terminó en 86.67%. No aparece una caída grande entre entrenamiento y los otros conjuntos, por lo que no se observa un problema importante de generalización.




Figura 1. Curva de aprendizaje del modelo base.

4.2 Diagnóstico de bias, varianza y ajuste

El bias se consideró medio porque incluso sobre entrenamiento el modelo alcanza 88.89% de accuracy. Esto indica que el modelo todavía deja algunos errores dentro del conjunto que utilizó para formar los centroides. La varianza se consideró baja porque la diferencia máxima entre entrenamiento y los otros conjuntos es de aproximadamente 4.44 puntos porcentuales. Las curvas también se mantienen cercanas y no muestran una separación progresiva entre Train y Validation.

Con ambos resultados, el modelo base se clasificó como underfit leve. El problema principal no es que memorice el entrenamiento, sino que su desempeño dentro de Train todavía puede mejorar.

5. Ajuste del modelo

5.1 Búsqueda con el conjunto de validación

K-Means no utiliza una regularización L1 o L2 como otros modelos. Por esta razón se aplicó la alternativa indicada en la actividad: ajuste de parámetros. Se compararon las inicializaciones k-means++ y random, valores de n_init de 10, 20 y 50, y tolerancias de 0.001 y 0.0001. También se revisaron distintos subconjuntos de variables para comprobar si todas aportaban a la separación de los clusters.




Figura 2. Mejor accuracy de Validation para cada conjunto de variables.

La mejor configuración en Validation utilizó únicamente petal length y petal width. Estas dos variables concentran la separación más clara entre las especies de Iris. El modelo seleccionado conservó $k = 3$ y k -means++, aumentó n_init a 50 y utilizó una tolerancia de 0.001. La elección se realizó antes de consultar los resultados de Test.

5.2 Resultados después del ajuste

Conjunto	Accuracy	F1 macro	Silhouette
Train	96.67%	96.67%	0.6705
Validation	100.00%	100.00%	0.6450
Test	93.33%	93.33%	0.6029

Después del ajuste, Train subió a 96.67%, Validation a 100.00% y Test a 93.33%. También aumentó silhouette en los tres conjuntos, lo que indica que los clusters quedan más separados al trabajar con las variables del pétalo.




Figura 3. Curva de aprendizaje del modelo ajustado.

El bias del modelo ajustado se clasificó como bajo porque el accuracy de entrenamiento alcanzó 96.67%. La varianza continuó siendo baja: la mayor diferencia entre entrenamiento y los otros conjuntos fue de 3.33 puntos porcentuales. Con un desempeño alto en Train y resultados cercanos en Validation y Test, el modelo se clasificó como fit.

6. Comparación antes y después del ajuste




Figura 4. Comparación del accuracy del modelo base y del modelo ajustado.

La mejora más importante se observa en el conjunto de prueba, donde el accuracy pasó de 86.67% a 93.33%. El cambio equivale a 2 observaciones adicionales clasificadas correctamente dentro de las 30 utilizadas para Test. El resultado también mejora en entrenamiento y validación, por lo que el aumento no depende únicamente de un conjunto.




Figura 5. Matrices de confusión en Test: modelo base (izquierda) y modelo ajustado (derecha).

En el modelo base se observan cuatro errores en Test. Después del ajuste quedan dos. Setosa se mantiene completamente separada y los errores restantes se concentran entre versicolor y virginica, que son las especies con mayor cercanía en sus medidas.

7. Discusión

La comparación muestra que el modelo base no presentaba una varianza alta. Train, Validation y Test daban resultados relativamente cercanos, por lo que no había evidencia de overfit. El punto a mejorar era el desempeño de entrenamiento, que se encontraba por debajo de 90%. Esto es consistente con un underfit leve.

El ajuste encontró una representación más simple del problema utilizando las dos medidas del pétalo. Con estas variables aumentaron tanto las métricas relacionadas con las especies como silhouette. Esto sugiere que las variables de sépalos agregaban información menos útil para separar los tres grupos en este caso. El resultado final mantiene una diferencia pequeña entre Train y Test, por lo que la mejora no estuvo acompañada de un aumento importante en varianza.

8. Conclusiones

La separación Train / Validation / Test permitió evaluar el comportamiento del modelo sin utilizar las mismas observaciones para todas las decisiones. El modelo base presentó bias medio, varianza baja y un nivel de ajuste underfit. Después de comparar configuraciones únicamente con Validation, se seleccionó un modelo con las variables de longitud y ancho del pétalo, $n_{init} = 50$ y tolerancia de 0.001.

El modelo ajustado alcanzó 96.67% de accuracy en Train, 100.00% en Validation y 93.33% en Test. Con estos resultados el bias se redujo a bajo, la varianza se mantuvo baja y el nivel de ajuste se consideró fit. En prueba, el accuracy aumentó 6.66 puntos porcentuales respecto al modelo base, por lo que el ajuste mejoró el desempeño sin mostrar señales de overfit.